

岩石力学与工程学报
Chinese Journal of Rock Mechanics and Engineering
ISSN 1000-6915, CN 42-1397/O3

《岩石力学与工程学报》网络首发论文

题目：基于振动信号的岩石单轴抗压强度钻进预测实验研究
作者：郝建，刘河清，刘建康，吕家庆，郑义宁，刘建荣
DOI：10.13722/j.cnki.jrme.2023.0960
收稿日期：2023-10-19
网络首发日期：2024-02-02
引用格式：郝建，刘河清，刘建康，吕家庆，郑义宁，刘建荣. 基于振动信号的岩石单轴抗压强度钻进预测实验研究[J/OL]. 岩石力学与工程学报.
<https://doi.org/10.13722/j.cnki.jrme.2023.0960>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于振动信号的岩石单轴抗压强度钻进预测实验研究

郝建¹, 刘河清¹, 刘建康¹, 吕家庆¹, 郑义宁², 刘建荣³

(1. 山东科技大学 能源与矿业工程学院, 山东 青岛 266590; 2. 山东能源集团鲁西矿业有限公司 郭屯煤矿, 山东 菏泽 274700;

3. 内蒙古上海庙矿业有限责任公司 院士专家工作站, 内蒙古 鄂尔多斯 016299)

摘要: 为了研究钻进振动信号与岩体地质力学参数之间的响应关系, 准确、快速地感知、预测岩石单轴抗压强度, 开展了基于钻进振动信号的岩石单轴抗压强度预测研究。以室内钻取花岗岩、石灰岩、砂岩和煤四类原岩(煤)试件实验为基础, 结合傅里叶变换和振动信号降噪方法构建 GA-BP 神经网络模型, 并对比分析了降噪前后以及不同降噪方法模型的预测性能。结果表明: 钻进振动信号与岩石单轴抗压强度之间有响应关系, 应用钻进振动信号可预测岩石单轴抗压强度; 采用 Adobe Audition 软件对振动信号进行降噪处理的 GA-BP 神经网络预测模型决定系数 R^2 为 0.838, 均方根误差为 7.063 MPa, 平均绝对误差为 5.347 MPa, 其结果优于原始预测模型和一般降噪方法预测模型; 与原始预测模型相比, 最优降噪模型在预测精度上提升了 6.3%, 均方根误差减小 1.954 MPa, 平均绝对误差减小 1.621 MPa; 同一预测模型中不同岩性的预测效果存在一定差异。降噪信号 GA-BP 神经网络预测模型对单轴抗压强度有较优秀的预测能力, 所用方法可为在岩体地质力学参数随钻测量方面提供基础。

关键词: 岩石力学; 钻进振动信号; 单轴抗压强度; 傅里叶变换; 信号降噪; 人工神经网络

中图分类号: TU 45

文献标识码: A

文章编号: 1000 - 6915(2024)00 - 0000 - 19

Experimental study of rock uniaxial compressive strength prediction with drilling based on vibration signals

HAO Jian¹, LIU Heqing¹, LIU Jiankang¹, LYU Jiaqing¹, ZHENG Yining², LIU Jianrong³

(1. College of Energy and Mining Engineering, Shandong University of Science and Technology, Qingdao, Shandong 266590,

China; 2. Guotun Coal Mine, Shandong Energy Group Luxi Mining Co., Ltd., Heze, Shandong 274700, China;

3. Academician(Expert) Workstation, Inner Mongolia Shanghaimiao Mining Co., Ltd., Erdos, Inner Mongolia 016299, China)

Abstract: In order to study the response relationship between the vibration signal with drilling and the geomechanical parameters of the rock mass, and to perceive and predict the uniaxial compressive strength of the rock accurately and quickly, a research on the prediction of uniaxial compressive strength of the rock based on the vibration signal with drilling was carried out. Based on indoor drilling experiments of four types of raw rock(coal) specimens, namely granite, limestone, sandstone and coal, the GA-BP neural network model was constructed by combining Fourier transform and vibration signal noise reduction methods, and the prediction performance of the model before and after the noise reduction, as well as the models with different noise reduction methods, were

收稿日期: 2023 - 10 - 19; **修回日期:** 2023 - 12 - 28

基金项目: 国家自然科学基金资助项目(52174121, 52204099); 山东省自然科学基金资助项目(ZR2022QE203)

Supported by the National Natural Science Foundation of China(Grant Nos. 52174121 and 52204099) and Natural Science Foundation of Shandong Province, China(Grant No. ZR2022QE203)

作者简介: 郝建(1986 -), 男, 2015 年于山东科技大学采矿工程专业获博士学位, 现任副教授、硕士生导师, 主要从事矿山岩层控制、无煤柱开采方面的研究工作。E-mail: skdhaojian@sdust.edu.cn. 通讯作者: 刘建康(1988 -), 男, 博士, 现任助理研究员。E-mail: ljk@sdust.edu.cn

DOI: 10.13722/j.cnki.jrme.2023.0960

compared and analyzed. The results show that there is a responsive relationship between the vibration signal with drilling and the uniaxial compressive strength of rock, and the uniaxial compressive strength of rock can be predicted by using the vibration signal while drilling. The GA-BP neural network prediction model using Adobe Audition software to denoise the vibration signal has a determination coefficient R^2 of 0.838, a root mean square error of 7.063 MPa, and an average absolute error of 5.347 MPa. The results are better than the original prediction model and the general noise reduction method prediction model. Compared with the original prediction model, the prediction accuracy of the optimal noise reduction model is improved by 6.3%, the root mean square error is reduced by 1.954 MPa, and the average absolute error is reduced by 1.621 MPa. There are some differences in the prediction effect of different lithology in the same prediction model. The GA-BP neural network prediction model of noise reduction signal has excellent prediction ability for uniaxial compressive strength. The method can provide a basis for the measurement of rock mass geomechanical parameters while drilling.

Key words: rock mechanics; vibration signals with the drill; uniaxial compressive strength; Fourier transform; signal noise reduction; artificial neural networks

1 引言

岩体地质力学参数尤其是岩石单轴抗压强度在岩石力学领域发挥着及其重要的作用,广泛应用于与岩石相关的工程与研究中。快速准确地获取岩体地质力学参数是岩石力学及相关工程智能发展的重要前提,无论在隧道开挖、煤矿井下开采还是在地下空间工程等方面都意义重大。在岩土工程中,钻孔破岩是必不可少的部分,随钻振动信号的产生伴随钻孔破岩的始终。大量的随钻振动信号正是分析研究岩体地质力学参数的优良媒介,岩石破碎与随钻振动信号之间有着密切的联系,据此可基于随钻振动信号感知预测岩体地质力学参数。

随钻参数能够表征围岩特性,应用随钻参数可实现岩性的识别^[1-2],随着研究不断深入,随钻参数更是感知岩石强度^[3-4]和围岩应力^[5]的关键所在。针对岩石单轴抗压强度的预测方法,国内外学者已经做了大量的研究,主要分为三种:一是通过室内实验测试岩石相关参数,构建模型对岩石单轴抗压强度进行预测^[6-12];二是开展室内钻测实验,以室内钻测数据建立与岩石强度的响应关系,进一步反演岩石单轴抗压强度^[13-14];三是通过数字钻探的方法,以现场钻测数据快速测量围岩强度^[15-18]。上述大量研究中,所应用的随钻参数绝大多数是钻机钻进过程中产生的实际参量,例如钻进速率、给进力等,其采集、记录过程任务繁琐。而随钻参数数据量庞大,不仅产生钻进数据,伴随钻进过程还有大量随钻振动信号产生,因此随钻振动信号与岩体地质力学参数之间的响应关系还需进一步研究。

应用随钻振动信号,国内外学者采用不同的分析方法对所研究对象进行分类识别。首先从不同层面对不同种类的岩石进行振动特性分析^[19-21],建立振动模型识别岩性及岩层破裂情况^[22-23],实现了以振动特性识别岩层不同介质以及煤岩破碎范围。随各学者对振动信号的分析不断深入,发现振动信号与电磁波信号相似,具有部分相同的特征,采用分析电磁波信号常用的时域、频域分析方法,对随钻振动信号进行时域、频域特征分析,揭示了不同种类岩石的振动特性差异与振动模式^[24-25]。应用随钻振动信号的时域、频域特征,可构建机器学习模型,实现对凿岩工具、岩石种类以及工作面的分类识别^[26-29]。在应用振动信号预测其他参数方面,Lawal等^[30]运用花岗岩的爆破振动信号建立神经网络等模型预测了岩石爆破参数峰值颗粒速度(PPV),研究了特殊情况下振动信号与PPV的响应关系。对随钻振动信号的应用中,大多都聚焦在对岩性以及地层的识别方面,随钻振动信号与岩石单轴抗压强度之间有怎样的响应关系尚不明确,以随钻振动信号反演、预测岩石强度的研究还未全面深入开展,而随钻振动信号采集过程简便、无需耗费大量人力物力,故以随钻振动信号预测岩石单轴抗压强度的研究具有重大意义。

为了揭示钻进振动信号与岩石单轴抗压强度的响应关系,准确、快速预测岩石单轴抗压强度,本文结合钻进振动信号与降噪方法,开展了不同种类岩石室内钻取实验,构建了基于降噪钻进振动信号的岩石单轴抗压强度 GA-BP 神经网络预测模型,如图 1 所示。在采集的随钻振动信号中,一般都混有环境中的噪音,噪音对振动信号的特征具有一定的

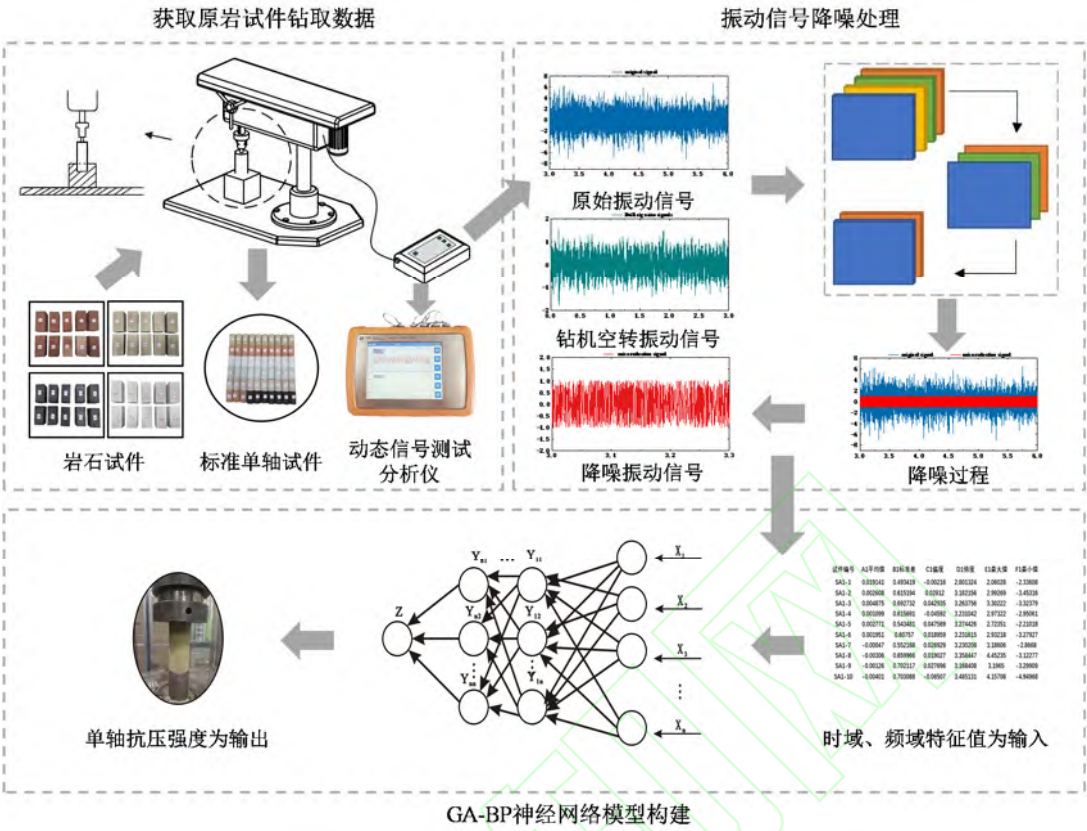


图 1 研究思路流程图

Fig.1 Flowchart of research ideas

影响，为了突出原始振动信号特征，参照一般降噪方法^[31-36]，并结合降噪原理，对振动信号进行降噪处理。基于实验结果，分析了振动信号降噪前后与岩石单轴抗压强度的响应关系和预测精度，并对模型结果进行讨论。研究成果可为岩体地质力学参数准确预测提供理论方法。

2 实验方法与数据





2.1 实验材料

根据岩石强度划分标准并参照煤矿井下岩层柱状图，分别选取了煤、砂岩、石灰岩和花岗岩四类岩石作为本文研究的实验材料。选取的煤单轴抗压强度分布于 4~20 MPa，共 20 个试件，其中最大值为 20.850 MPa，最小值为 4.663 MPa，平均值为 9.998 MPa；砂岩的单轴抗压强度分布于 6~60 MPa，分为 6 种不同种类共 60 个试件，其中最大值为 53.015 MPa，最小值为 6.215 MPa，平均值为 31.148 MPa；石灰岩的单轴抗压强度主要分布于 50~60 MPa(偶有两个强度较小分别为 8.456，19.015 MPa，此处并未标记)共 10 个试件，其中最大值为 58.024 MPa，最小值为 51.089 MPa，平均值为 54.997 MPa；花岗岩

岩的单轴抗压强度分布于 39~70 MPa，分为 3 种不同种类共 30 个试件，其中最大值为 70.225 MPa，最小值为 39.950 MPa，平均值为 60.127 MPa；总试件数为 120 个(如表 1 和图 2 所示)。

表 1 岩石试件强度分布统计表

Table 1 Statistical table of strength distribution of rock specimens

岩石种类	图	单轴抗压强度分布/MPa	最大值/MPa	最小值/MPa	平均值/MPa	试件数量/个
煤		4~20	20.850	4.663	9.998	20
砂岩		6~60	53.015	6.215	31.148	60
石灰岩		50~60	58.024	51.089	54.997	10
花岗岩		39~70	70.225	39.950	60.127	30
合计	-	-	-	-	-	120




图2 岩石试件强度分布箱线图

Fig.2 Box plot of strength distribution of rock specimen

试件加工成 70 mm×70 mm×110 mm 的立方体如图 3 所示, 其中, 长为 70 mm, 宽为 70 mm, 高为 110 mm。编号规则为 X_{mn} 如图 4 所示, 其中“X”为岩石种类缩写, 煤编号为“C”, 砂岩编号为“SA”, 石灰岩编号为“L”, 花岗岩编号为“G”; “m”为强度种类编号, “n”为同种强度的试件序号, 例如 G_{32} , 为花岗岩第 3 种强度第 2 个试件编号。




图3 试件尺寸

Fig.3 Dimensions of test pieces




图4 部分试件

Fig.4 Partial specimen

2.2 钻进数据采集

(1) 钻进振动信号采集设备和方法

采用室内 YJ-2 型岩芯钻取机、UBP-02 型岩芯切磨机和 DH5909N 手持式动态信号测试分析仪(如

图 5 所示)共同完成数据采集过程。其中岩芯钻取机和岩芯切磨机将试件加工成标准岩芯($\Phi 50\text{mm} \times 100\text{mm}$) 钻进振动信号采用 DH5909N 手持式动态信号分析仪连接 IEPE 加速度传感器采集, 采样频率为 2 000 Hz。



(a) 数据采集过程



(b) 动态信号分析仪

图5 动态信号分析及数据采集过程


Fig.5 Dynamic signal analyzer and data acquisition process

具体采集方法为:

(a) 调试好岩芯钻取机并固定试件于合适的位置上;

(b) 连接动态信号测试分析仪的加速度传感器至室内岩芯钻取机上, 同时开启岩芯钻取机和动态信号测试分析仪, 将立方体试件钻取成圆柱形岩芯, 在钻取岩芯的过程中采集试件的钻进振动信号, 其中动态信号测试分析仪采集的原始信号为时域的振动波形信号;

(c) 将钻取的岩芯放到岩芯切磨机上制作成大小为 $\Phi 50\text{mm} \times 100\text{mm}$ 的标准岩芯(如图 6 所示), 为测试岩石力学性质做准备。



(a) 部分标准岩芯试件 (b) 单轴压缩过程

图 6 标准岩芯试件及单轴压缩过程

Fig.6 Standard rock core specimens and uniaxial compression process

(2) 岩石单轴抗压强度测定

采用 BGYD-600 变刚度实验加载系统对取好的岩芯进行单轴压缩，获取单轴抗压强度等岩体地质力学参数。

本节所述钻进振动信号采集方法仅限室内实验开展，若将此方法应用于现场实际钻取情境中，应以现场钻机替换室内取芯机。由于其钻进振动信号采集对象及所处环境不同，其振动信号数据所包含噪音亦不相同，应单独采集钻机空转振动信号与钻进振动信号进行比较，采取适当方法消除噪音。且室内实验获取的岩石单轴抗压强度应以其他参数进行替换。

2.3 时域、频域特征值提取

时域分析是以时间轴为坐标表示动态信号的关系，频域分析是把信号变为以频率轴为坐标表示出

来。钻进振动信号的原始输出为时域的振动波形信息，仅通过时域信息，难以分析不同种类、不同强度岩石的钻进振动信号有何内在联系与差异。故将钻进振动信号进行量化处理，提取振动信号的时域、频域特征值，将特征值作为分析的媒介。

(1) 时域

本文共选取了时域特征值 A1 平均值、B1 标准差、C1 偏度、D1 峭度、E1 最大值、F1 最小值、G1 峰峰值、H1 均方差、I1 振幅因数、J1 波形因数、K1 冲击因数、L1 裕度因数、M1 能量等共 13 个。以 MATLAB 进行时域特征值的提取，其计算公式如表 2 所示。其中， $x(n)$ 为信号的时域序列， $n = 1, 2, \cdots, N$ ； N 为样本点数。

(2) 频域

振动信号在时域上很难分辨其特征，将振动信号变换至频域，振动信号特征更易于分析。提取频域特征的方法有多种，应用最为广泛的是傅里叶变换法。

傅里叶变换(Fourier Transform)是一种将一个函数从时域(时间域)转换到频域(频率域)的数学变换。它基于傅里叶分析的思想，可以将一个周期性函数或非周期性函数表示为一系列正弦和余弦函数的叠加。傅里叶原理表明任何连续测量的时序或信号，都可以表示为不同频率的正弦波信号的无限叠加。根据此原理，傅里叶变换算法利用直接测量到的原始信号，以累加方式计算信号中不同正弦波信号的频率、振幅和相位。

应用傅里叶变换法提取振动信号的频域特征，同样应用时域特征值提取方法提取频域的 13 个特

表 2 时域特征值计算公式

Table 2 Time domain eigenvalue calculation formula

序号	特征值	计算公式	序号	特征值	计算公式
A1	平均值	$\bar{x} = \frac{1}{N} \sum_{n=1}^N x(n)$	H1	均方差	$x_{ms} = \sqrt{\frac{1}{N} \sum_{n=1}^N x^2(n)}$
B1	标准差	$\sigma_x = \sqrt{\frac{1}{N-1} \sum_{n=1}^N [x(n) - \bar{x}]^2}$	I1	振幅因数	$x_r = \left(\frac{1}{N} \sum_{n=1}^N \sqrt{ x(n) } \right)^2$
C1	偏度	$S = \frac{\sum_{n=1}^N [x(n) - \bar{x}]^3}{(N-1)\sigma_x^3}$	J1	波形因数	$W = \frac{x_{rms}}{\bar{x}}$
D1	峭度	$K = \frac{\sum_{n=1}^N [x(n) - \bar{x}]^4}{(N-1)\sigma_x^4}$	K1	冲击因数	$I = \frac{x_p}{\bar{x}}$
E1	最大值	$x_{\max} = \max(x_n)$	L1	裕度因数	$L = \frac{x_p}{x_r}$
F1	最小值	$x_{\min} = \min(x_n)$	M1	能量	$E = \sum_{n=1}^N x^2(n)$
G1	峰峰值	$x_p = \max x(n) $			

征值，其中包括：A2 平均值、B2 标准差、C2 偏度、D2 峭度、E2 最大值、F2 最小值、G2 峰峰值、H2 均方差、I2 振幅因数、J2 波形因数、K2 冲击因数、L2 裕度因数、M2 能量等。

2.4 钻进数据及分析

室内岩石试件钻进实验采集了大量的钻进振动信号，其中煤、砂岩、石灰岩、花岗岩四种岩石的钻进振动信号的时域、频域特征如图 7，8 所示：

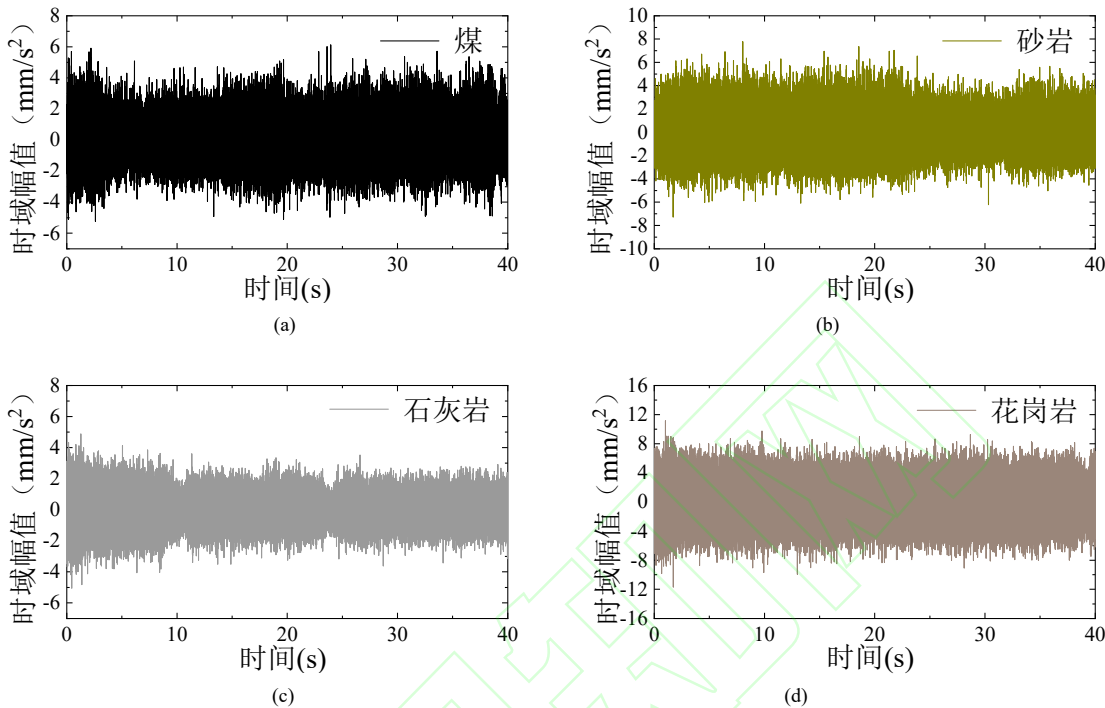


图 7 部分岩石(煤)试样振动信号时域特征

Fig.7 Time-domain characteristics of vibration signals of some rock(coal) specimens

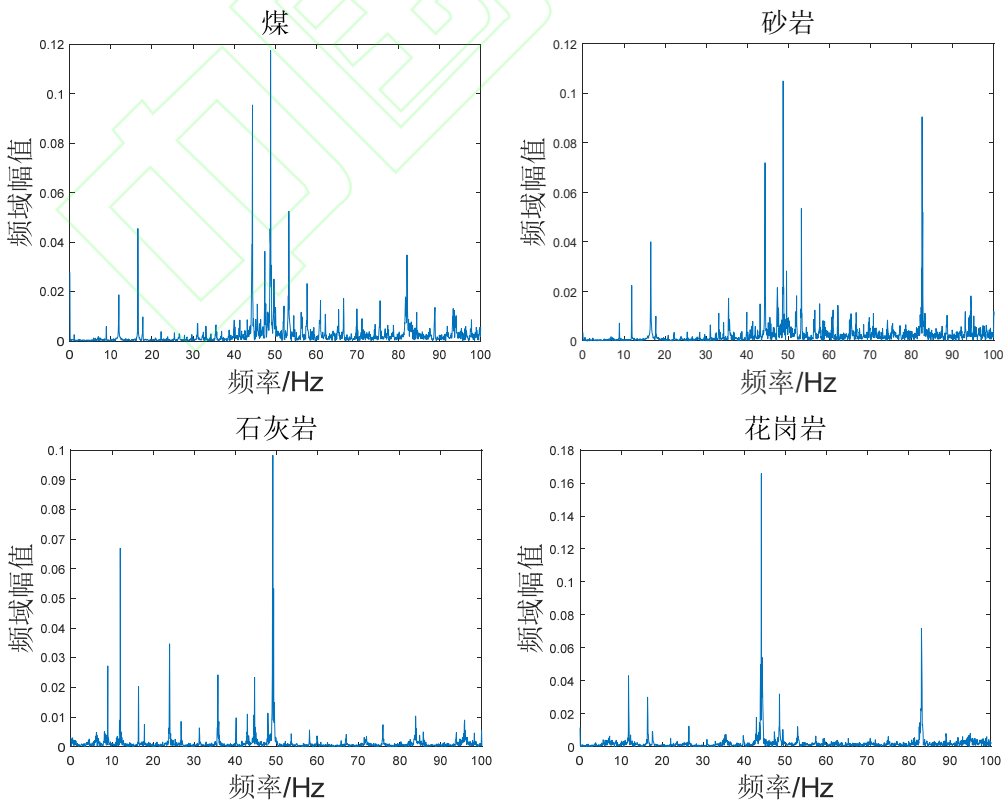


图 8 部分岩石(煤)试样振动信号频域特征

Fig.8 Frequency domain characteristics of vibration signals of some rock (coal) specimens

图 7 中, 时域幅值煤试件分布在 $-6 \sim 6 \text{ mm/s}^2$, 砂岩试件分布在 $-7 \sim 7 \text{ mm/s}^2$, 石灰岩试件分布在 $-4 \sim 4 \text{ mm/s}^2$, 花岗岩试件分布在 $-10 \sim 10 \text{ mm/s}^2$; 不同种类、不同强度岩石间时域幅值差值较小, 不易直接通过时域幅值分辨岩石种类及特性。

结合频域幅值特征(如图 8), 煤、砂岩和花岗岩三种试样的都有相似的三个峰值, 分别位于频率为 $10 \sim 20 \text{ Hz}$, $40 \sim 60 \text{ Hz}$, $80 \sim 90 \text{ Hz}$ 三处, 此处简称为“前锋”“中峰”和“后峰”。花岗岩“中峰”值最大为 0.16; 煤和砂岩的频域幅值信号中“前锋”和“中峰”基本保持一致, “后峰”煤试件为 0.04, 而砂岩试件为 0.09。石灰岩的频域幅值仅在频率为 $10 \sim 20 \text{ Hz}$ 和 $40 \sim 60 \text{ Hz}$ 处出现两个峰值, 与其他三种岩石频域特征不同。综上可知, 根据频域幅值峰值的数量和大小可粗略分辨出岩石种类。

通过振动信号的时域、频域特征分析, 能够反映出不同岩性的振动特性, 可据此粗略分辨岩石种类及其特性。

3 振动信号降噪方法

在机械振动信号降噪方法中, 出现频率最高的就是滤波器和小波降噪, 其中最常用的就是非线性小波变换阈值法降噪。非线性小波变换阈值法降噪主要适用于信号中混有白噪声的情况。用阈值法去噪的优点是噪声几乎完全得到抑制, 且反映原始信号的特征尖峰点得到很好的保留。用软阈值的方法去噪能够使估计信号实现最大均方误差最小化, 即去噪后的估计信号是原始信号的近似最优估计; 且估计信号至少和原始信号同样光滑而不会产生附加振荡。在非线性小波变换阈值法降噪中, 阈值的选择对降噪效果至关重要。但对于振动信号频率信息未知, 原始振动信号与环境噪声无法分辨的情况下, 非线性小波阈值降噪仍需要采用试错法, 不断调节软、硬阈值, 得到一个最优的降噪方法。在整个小波降噪过程中, 步骤冗杂, 阈值过大或过小都会影响振动信号的降噪效果。故本文采用较便于实现的 MATLAB 小波降噪工具箱与新结合的 Adobe Audition 音频处理软件对振动信号进行降噪处理。并分析比较两种降噪方法的效果。

3.1 降噪原理

3.1.1 振动产生与振动信号

物体产生振动的原理是由于外界力或能量作用于物体上, 引起物体内部分子、原子或结构的相互

作用和相对运动, 导致物体发生周期性的变形、位移或能量传递, 从而产生振动现象。本文研究的岩石振动信号是由钻机给予外界激励造成的振动现象。

物体振动发出的频率是物体的固有属性, 不同的岩石在钻取过程中产生的振动频率也不相同。根据振动源不同发出的振动频率不同这一物理特性, 可将钻机振动频率与岩石振动频率进行区分。不同频率振动信号的分离一般包括频谱分析、分离信号和信号重建 3 个过程。

频谱分析: 将原始振动信号转换到频域, 得到其频谱表示;

分离信号: 使用特定的算法(例如盲源分离)来找到振动噪音在频谱中的位置, 并将其从原始振动信号中分离出来。这通常涉及到把振动信号分解成不同的频带或子带, 并聚合这些信息来识别噪音的声谱特征;

信号重建: 使用分离出的噪音和原始振动信号的差异, 在频域上重建振动信号。通常需要把噪音的信号再转换回时间域, 并和原始振动信号融合起来。

为了提高信号分离的准确度, 专门采集一组取芯机钻取过程中空转的振动信号作为噪音信号, 并将其从原始信号中分离。

振动信号降噪主要包括滤波法降噪和小波降噪两种, 其降噪原理如下:

3.1.2 振动信号降噪滤波原理

假设一个混有噪音的振动信号表示为:

$$x(t) = s(t) + n(t) \quad (1)$$

其中 $s(t)$ 表示原始振动信号, $n(t)$ 表示噪声。

采用滤波的方法从 $x(t)$ 中去除噪音, 得到更加清晰的 $s(t)$ 信号。首先, 根据噪声的性质, 得到其功率谱密度为常数:

$$S_n(f) = K \quad (2)$$

其中 K 是常数。而振动信号的功率谱密度可以表示为:

$$S_x(f) = S_s(f) + S_n(f) \quad (3)$$

其中 $S_s(f)$ 是原始振动信号的功率谱密度。

为去除噪声部分, 需选择一个合适的滤波器 $H(f)$ 对信号进行滤波处理:

$$\hat{S}_x(f) = H(f) S_x(f) \quad (4)$$

根据 Wiener 滤波器的原理, 可以通过最小化误差信号的功率谱与真实信号功率谱之间的差异来求得最优的滤波器:

$$H_{opt}(f) = \frac{S_s(f)}{S_x(f)} = \frac{S_s(f)}{S_s(f) + K} \quad (5)$$

最后, 将最优滤波器 $H_{opt}(f)$ 代入到滤波公式中, 可得到去噪后的信号:

$$\hat{s}(t) = F^{-1}\{\hat{S}_x(f)\} = F^{-1}\{H_{opt}(f)S_x(f)\} \quad (6)$$

其中 $F^{-1}\{\}$ 表示傅里叶反变换, $\hat{s}(t)$ 表示去噪后的振动信号。

数字滤波通常使用差分方程描述, 离散时间傅里叶变换(DTFT)用于分析其频域特性。考虑一个数字滤波器的输入信号为 $x[n]$, 输出信号为 $y[n]$, 滤波器的差分方程为:

$$y[n] = b_0 x[n] + b_1 x[n-1] + \dots + b_M x[n-M] - a_1 y[n-1] - \dots - a_N y[n-N] \quad (7)$$

其中, b_0, b_1, \dots, b_M 和 a_1, \dots, a_N 是滤波器的系数, M 和 N 分别表示滤波器的前向和反馈延迟。

对差分方程进行 Z 变换, 我们可以得到滤波器的传递函数 $H(z)$

$$H(z) = \frac{Y(z)}{X(z)} = \frac{b_0 + b_1 z^{-1} + \dots + b_M z^{-M}}{1 + a_1 z^{-1} + \dots + a_N z^{-N}} \quad (8)$$

其中, $X(z)$ 和 $Y(z)$ 分别表示输入和输出信号的 Z 变换。

接下来, 通过对 $H(z)$ 进行频域分析, 得到滤波器的频率响应。频率响应通常通过单位圆上的点来表示, 将 $z = e^{j\omega}$ 代入 $H(z)$ 中, 得到频率响应 $H(e^{j\omega})$ 。

最常见的频率响应包括幅度响应 $|H(e^{j\omega})|$ 和相位响应 $\angle H(e^{j\omega})$ 。

通过分析上述响应, 可以了解滤波器在不同频率下的衰减或增益以及相位变化情况, 从而选取合适的滤波器。

3.1.3 振动信号小波降噪原理

一个混杂着噪音的信号 $x(t)$, 使用小波降噪方法将噪声从中去除, 得到更加清晰的信号 $\hat{x}(t)$ 。

首先, 将信号 $x(t)$ 进行小波变换。小波变换将信号分解成不同尺度和频率的小波系数, 可以表示为:

$$x(t) = \sum_{j=0}^{J-1} \sum_k a_{j,k} \phi_{j,k}(t) + \sum_{j=0}^{J-1} \sum_k d_{j,k} \psi_{j,k}(t) \quad (9)$$

其中, $a_{j,k}$ 表示近似系数, $d_{j,k}$ 表示细节系数, $\phi_{j,k}(t)$ 和 $\psi_{j,k}(t)$ 分别表示小波函数和小波基。

接下来, 需对小波系数进行阈值处理。阈值处理通过对小波系数的幅值进行比较, 并根据设定的阈值参数决定是否将其置零或保留。常用的阈值处理方法包括硬阈值和软阈值。

对于硬阈值方法, 阈值处理公式为:

$$\hat{a}_{j,k} = \begin{cases} a_{j,k}, & |a_{j,k}| > T \\ 0, & |a_{j,k}| \leq T \end{cases} \quad (10)$$

$$\hat{d}_{j,k} = \begin{cases} d_{j,k}, & |d_{j,k}| > T \\ 0, & |d_{j,k}| \leq T \end{cases} \quad (11)$$

对于软阈值方法, 阈值处理公式为:

$$\hat{a}_{j,k} = \text{sgn}(a_{j,k})(|a_{j,k}| - T)_+ \quad (12)$$

$$\hat{d}_{j,k} = \text{sgn}(d_{j,k})(|d_{j,k}| - T)_+ \quad (13)$$

其中, $\text{sgn}(\bullet)$ 表示符号函数, 取正部分由 $(x)_+ = \max(0, x)$ 表示。

最后, 将处理后的小波系数进行逆小波变换, 得到去噪后的信号 $\hat{x}(t)$ 。

$$\hat{x}(t) = \sum_{j=0}^{J-1} \sum_k \hat{a}_{j,k} \phi_{j,k}(t) + \sum_{j=0}^{J-1} \sum_k \hat{d}_{j,k} \psi_{j,k}(t) \quad (14)$$

3.2 降噪方法及过程

降噪方法采用 MATLAB 小波降噪工具箱降噪法和 Adobe Audition 软件去除机器空转降噪法。

(1) 小波降噪过程

岩石振动信号小波降噪由 MATLAB 完成, 将振动信号导入小波降噪工具箱, 选取合适的小波基, 通过不断调节分解层数等参数(如图 9), 对岩石振动信号进行降噪处理。

(2) Adobe Audition 降噪过程

受音乐领域去除背景音乐技术的启发, 钻机空转的振动信号也可作为“背景音乐”去除, 故本文采用一种将钻机空转振动信号从整体信号中剥离的降噪方法。声音是由物体振动引起的机械波, 通过介质(如空气、水或固体)的传播而产生的。当物体振动时, 它会以波动的形式传递能量, 导致周围介质中的分子或粒子发生振动。这种振动通过介质中分子的相互作用和传递引起了声音的传播。振动信号与声音信号之间是可以相互转化的。

Adobe Audition 软件是一款专用于音频剪辑处理的软件, 可对音频进行人声提取放大、环境噪音去除等处理。此软件对音频处理快捷简便, 去除噪音的功能只需将噪音信号导入, 软件即可对选定信号自动剔除所导入的噪音信号。为利用此软件去除钻进振动信号的钻机空转振动信号, 采集一组钻机空转振动信号作为“噪音”信号, 将钻机空转振动信号去除。

本文采用的振动信号降噪过程如下:

① 采集取芯机空转时的振动信号(图 10(b))和钻取试件的振动信号(图 10(a));




图 9 小波降噪示意图

Fig.9 Schematic diagram of wavelet noise reduction

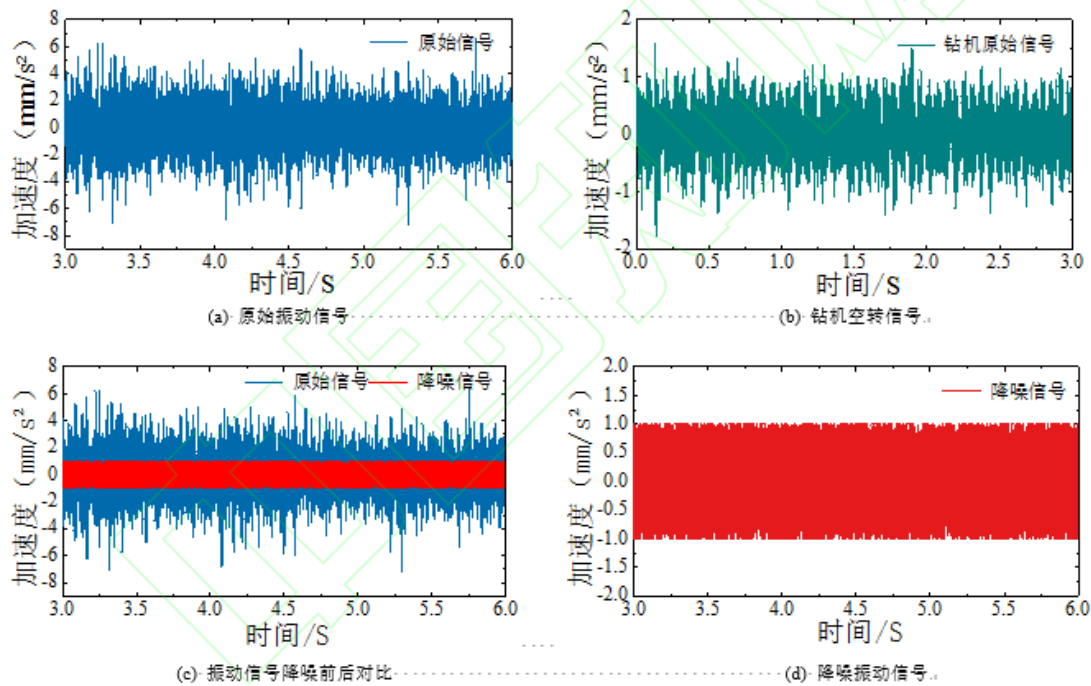
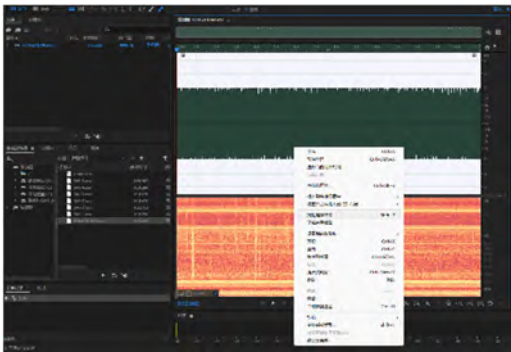


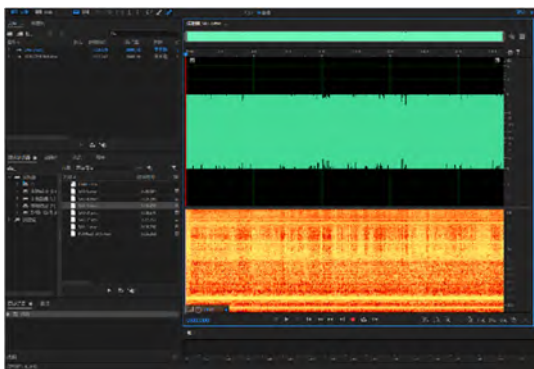
图 10 振动信号降噪示意图

Fig.10 Schematic diagram of vibration signal noise reduction

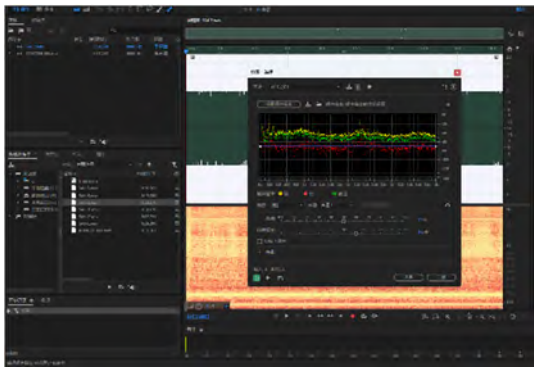
- ② 将采集的振动信号经 MATLAB 转化为相同转换频率的声音信号；
 - ③ 在 Adobe Audition 软件中选取取芯机空转时的声音信号为背景音，将每一个岩石试件声音信号中的取芯机声音信号去除，仅留下岩石振动时的声音信号(如图 11)；
 - ④ 将降噪完成的声音信号经 MATLAB 转换为振动信号(图 10(d))。
- 部分振动信号降噪前后变化如图 10(c)所示。



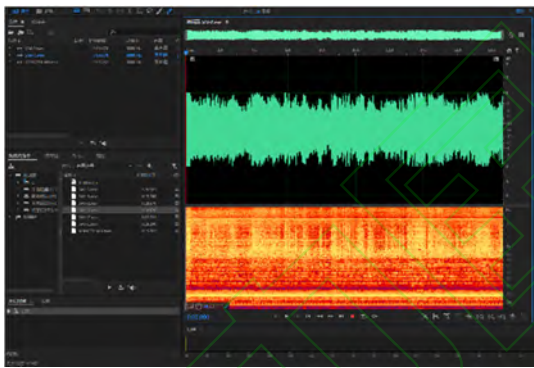
(a) 捕捉空转振动信号作为噪音样本



(b) 选择需要处理的振动信号样本



(c) 设置降噪百分比数值



(d) 获得降噪完成的样本

图 11 Adobe Audition 降噪过程

Fig.11 Adobe Audition noise reduction process

4 单轴抗压强度预测模型构建

本文以钻进振动信号的时域、频域特征值为输入，以单轴抗压强度为输出，建立 GA-BP 神经网络预测模型。分别构建原始振动信号模型和降噪振动信号模型，对比分析降噪前后对单轴抗压强度预测准确度的影响。

4.1 神经网络介绍

人工神经网络 (Artificial Neural Networks, 简称 ANN) 是一种模仿生物神经网络结构和功能的计算模型。它由大量的人工神经元(或称为节点)以及连接这些神经元的权重组成，通过这些连接进行信息

的传递和处理。它由输入层、隐藏层和输出层(图 12)组成，信息通过网络从输入层经过隐藏层传递到输出层。BP 神经网络是常用的人工神经网络的一种，通过反向传播算法来训练和调整网络的权重和偏置。




图 12 神经网络拓扑图

Fig.12 Neural network topology

GA-BP(Genetic Algorithm-Backpropagation)神经网络是一种结合了遗传算法(Genetic Algorithm)和反向传播算法(Backpropagation)的神经网络模型。传统的神经网络训练方法是使用反向传播算法，通过计算梯度来更新网络的权重和偏置。而 GA-BP 神经网络(如图 13 所示)则引入了遗传算法作为训练的辅助手段，用于优化神经网络的结构和参数。通过遗传算法的选择、变异和交叉操作，GA-BP 神经网络

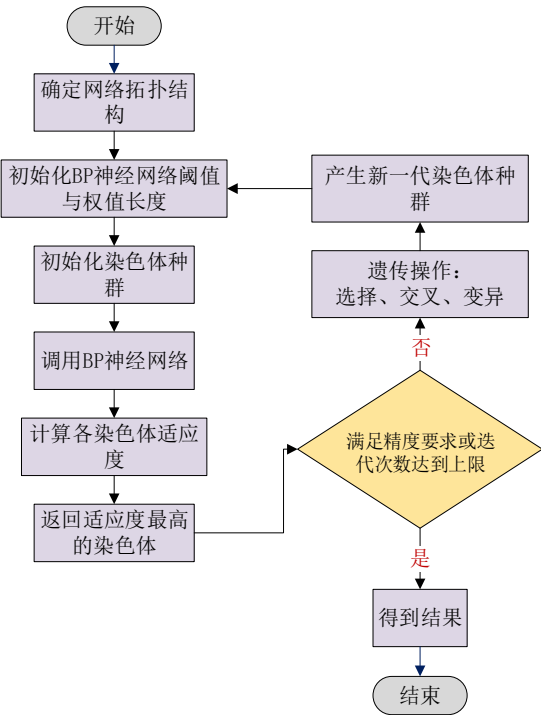


图 13 GA-BP 算法流程图

Fig.13 Flowchart of GA-BP algorithm

络可以在训练过程中搜索更好的网络结构和参数组合。这种结合了遗传算法和反向传播算法的方法可以提高神经网络的全局搜索能力和泛化性能，同时减少可能陷入局部最优解的风险。

GA-BP 神经网络是结合遗传算法和 BP 神经网络的一种混合模型，其中包含：

输入层：将输入的数据特征送入神经网络中。

隐藏层：用于提取数据特征的高阶表示，可以设定多层。

输出层：输出神经网络对输入数据的预测结果。

遗传算法优化器：在 BP 训练过程中，使用遗传算法来对神经网络的权重和偏置进行优化搜索，主要由种群数量控制优化结构。

BP 算法反向传播优化器：使用反向传播算法更新神经网络的权重和偏置，以减小预测误差，由隐含层数改变网络结构。

4.2 预测模型构建

4.2.1 原始信号预测模型

原始信号模型以原始钻进振动信号提取的时域、频域 26 个特征值为输入，以岩石单轴抗压强度

为输出，构建 GA-BP 神经网络预测模型。各输入特征值之间与输出单轴抗压强度有一定的相关性，其矩阵图如图 14。原始振动信号时域信号中，与单轴抗压强度相关性较大的有标准差、最大值、最小值、峰峰值、均方差和振幅因数 6 个，其相关系数都在 0.4~0.5 之间，虽然具有一定的相关性，但数值较小。忽略存在直接公式计算关系的特征值之间的相关性，各特征值之间的相关系数都很小，各自独立。

室内实验 120 个试件共得到 454 个样本，总体样本中随机选取 363(80%)个样本作为训练集，其余 91(20%)个样本作为测试集。原始信号模型以隐含层数量和种群大小为自变量，构建多组对照模型，依据模型预测结果选出最优的预测模型。隐含层数量分别设置为 5、8、10、12、15、18、20、22、25 共 9 组，各隐含层组分别设置种群数为 10、20、30、40、50、60、70、80、90、100，共 90 组预测结果。

训练模型均以 R^2 、 $RMSE$ 、 MAE 作为标准来衡量模型的拟合程度和准确度。

(1) 决定系数：解释离差平方和与总离差平方和之比，反应模型拟合程度。




图 14 部分原始输入、输出数据相关性矩阵图

Fig.14 Part of the original input and output data correlation matrix diagram

$$R^2 = 1 - \frac{\sum_i (\hat{y}_i - y_i)^2}{\sum_i (\bar{y}_i - y_i)^2} \quad (15)$$

(2) 均方根误差：均方根误差是预测值与真实值偏差的平方与观测次数 n 比值的平方根。衡量的是预测值与真实值之间的偏差，并且对数据中的异常值较为敏感。

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2} \quad (16)$$

(3) 平均绝对误差：表示预测值和观测值之间绝对误差的平均值。

$$MAE = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i| \quad (17)$$

MAE 与 $RMSE$ 相比，更加注重模型预测误差的平均程度而不是误差的平方和。 $RMSE$ 和 MAE 常用来比较不同模型的预测性能。 $RMSE$ 在处理变化幅度较大的数据时更为敏感，而 MAE 在处理异常值时更加鲁棒。同时应用 MAE 和 $RMSE$ ，能够在比较模型预测性能的基础上判断出预测结果奇异值的存在。

4.2.2 降噪信号预测模型

降噪信号模型以降噪钻进振动信号提取的时域、频域 26 个特征值为输入，以岩石单轴抗压强度为输出，构建 GA-BP 神经网络预测模型。将 3.2 节所述两种降噪振动信号分别构建新的预测模型，对比降噪前后预测模型性能和小波降噪方法与 Adobe Audition 降噪方法的预测模型性能。

采用小波降噪方法降噪的钻进振动信号时域、频域的特征值与原始钻进振动信号时域、频域特征值之间无明显相互关系，此处省略对此部分的分析。

采用 Adobe Audition 降噪方法的降噪振动信号结果中，各输入特征值之间与输出单轴抗压强度有一定的相关性，其矩阵图如图 15。降噪振动信号特征值中与单轴抗压强度相关性较大的有标准差、俏度、均方差、振幅因数、波形因数、冲击因数和能量共 7 个。其中，上述 7 个相关系数都大于 0.699，标准差、均方差和能量这 3 个特征值的相关系数都在 0.8 以上，最大的为 0.827。与原始振动信号特征值相关性相比，降噪后的振动信号特征值相关性整体提高，这能够充分说明振动信号降噪对相关性的显现有显著影响。这也将对整体预测模型的效果产生一定影响。

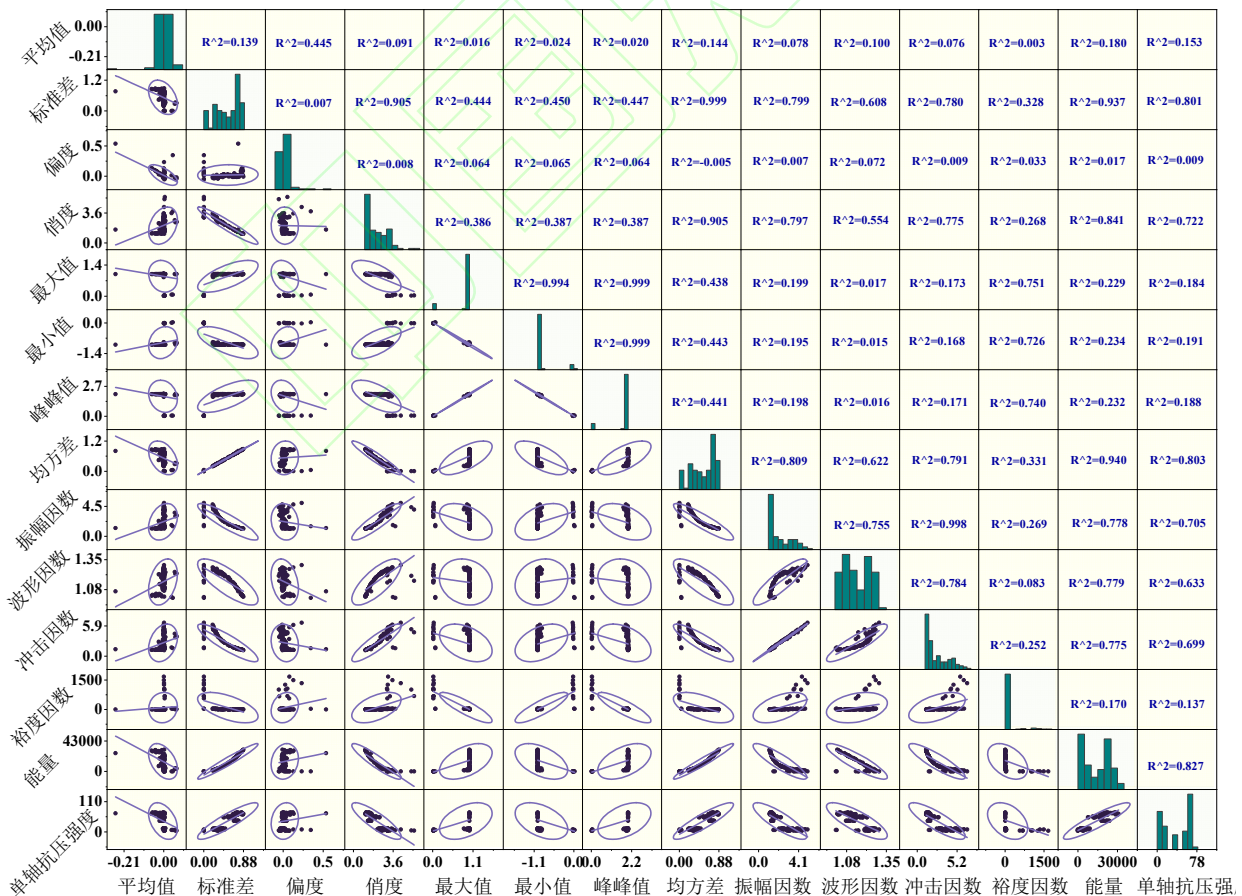


图 15 部分 Adobe Audition 降噪输入、输出数据相关性矩阵图

Fig.15 Partial Adobe Audition noise reduction input and output data correlation matrix diagram

振动信号降噪预测模型的结构与原始信号预测模型结构一致，详见 4.2.1 节。

4.3 结果与讨论

原始振动信号预测模型和降噪振动信号预测模型的预测结果皆为 90 组，为了便于分析、对比降噪前后的预测效果，在此选取降噪前后各隐含层的最优结果进行分析讨论。

4.3.1 原始预测模型结果

以原始振动信号的时域、频域特征值为输入构建的 GA-BP 神经网络模型经反复训练得到了如表 3 所示结果，图 16 为 R^2 统计图，图 17 为 $RMSE$ 和 MAE 结果统计图。




图 16 原始预测模型 R^2 结果
Fig.16 R^2 results of the original prediction model

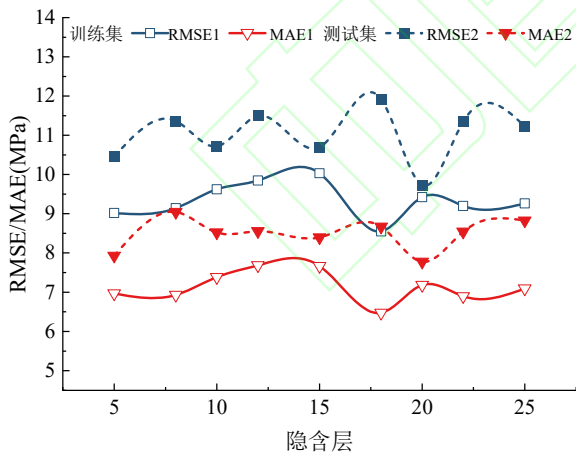


图 17 原始预测模型 $RMSE$ 和 MAE 结果
Fig.17 Original prediction model $RMSE$ and MAE results

由表 3 数据可以得知，原始振动信号预测模型可以较好的感知预测岩石的单轴抗压强度。其中，训练集决定系数都大于 0.73，最好的能够达到 0.803；测试集的决定系数都大于 0.61，最好能够达到 0.737；均方根误差范围在 8.5~12 MPa 之间，平均绝对误差在 6.4~9.5 MPa 之间，均方根误差与平均绝对误

表 3 原始预测模型结果

Table 3 Original prediction model results

隐含层	种群数	训练集			测试集		
		R^2_1	$RMSE_1$	MAE_1	R^2_2	$RMSE_2$	MAE_2
5	40	0.775	9.017	6.968	0.737	10.452	7.928
8	70	0.775	9.143	6.932	0.674	11.365	9.045
10	60	0.753	9.624	7.385	0.696	10.718	8.521
12	50	0.761	9.847	7.684	0.611	11.495	8.555
15	30	0.732	10.032	7.667	0.712	10.698	8.397
18	60	0.803	8.553	6.474	0.646	11.923	8.669
20	70	0.770	9.424	7.182	0.713	9.729	7.777
22	100	0.779	9.200	6.895	0.641	11.344	8.543
25	80	0.765	9.262	7.092	0.715	11.222	8.827

差的差值为 2 MPa 左右，说明其中仍有异常值的存在，有若干预测值与真实值之间的误差较大；但整体结果显示，误差值随决定系数在一定范围内上下浮动，误差在可接受范围内。

由图 16 可知，原始预测模型中，所有训练集 R^2 都高于测试集，未出现过拟合现象。为构建最优的神经网络模型，设置不同隐含层数与种群数量，并分析比较其预测效果。图 16 中，隐含层为 8、12、18、22 时，训练集与测试集的 R^2 差距较大，呈现出反峰趋势，说明此四种模型效果较差。其余五种隐含层结果稳定，隐含层为 5 时，训练集与测试集的 R^2 差距最小，效果最好。

图 17 中， $RMSE$ 与 MAE 的趋势与相对应的 R^2 保持相反， R^2 越大， $RMSE$ 与 MAE 数值越小，预测越准确。训练集中 $RMSE$ 与 MAE 变动趋势保持一致，预测集亦然。

在原始预测模型中，结合各隐含层最优结果，当隐含层为 5、种群数为 40 时预测结果整体最优 (如图 18 所示)。其训练集与测试集的决定系数十分接




图 18 原始预测最优模型拟合效果图
Fig.18 Plot of the effect of fitting the original prediction model

近, 均方根误差与平均绝对误差都较小, 可作为原始振动信号预测岩石单轴抗压强度的最优模型。隐含层为 18、种群数为 60 时, 虽然训练集的决定系数为 0.803, 是训练集中最大的, 但测试集的决定系数为 0.646, 由拟合图明显可以看出存在较多的异常值, 此时预测模型的整体效果不够优秀。故最优结果应为隐含层为 5、种群数为 40 的一组。

4.3.2 降噪预测模型结果

(1) 小波降噪模型结果

以小波降噪振动信号的时域、频域特征值为输入构建的 GA-BP 神经网络模型经反复训练得到了如表 4 所示结果, 小波降噪模型决定系数与误差统计如图 19 和图 20。

小波降噪预测模型结果中, 训练集中决定系数最优为 0.817, 最小为 0.722, 均方根误差最小为 8.201 MPa, 平均绝对误差最小为 5.896 MPa, 由图 19 和 20 可知, 隐含层为 8、18、22、25 时, 训练集与测试集决定系数与误差值相差较大, 此四组模型的




图 19 小波降噪预测模型 R^2 结果

Fig.19 Wavelet Noise reduction prediction model R^2 results




图 20 小波降噪预测模型 $RMSE$ 和 MAE 结果

Fig.20 Wavelet Noise reduction prediction model $RMSE$ and MAE results

预测效果不佳, 剩余五组预测效果浮动较小, 预测效果优良。隐含层为 20 时, 结合预测模型拟合图 (见图 23) 可知: 训练集、测试集决定系数分别为 0.805、0.728, 均方根误差分别为 8.201, 10.114 MPa, 平均绝对误差分别为 5.906, 7.953 MPa; 此时, 小波降噪预测模型最优。

(2) Adobe Audition 降噪模型结果

以 Adobe Audition 降噪振动信号的时域、频域特征值为输入构建的 GA-BP 神经网络模型经反复训练得到了如表 4 所示的结果, 图 21 为 R^2 统计图, 图 22 为 $RMSE$ 和 MAE 结果统计图。

由表格数据可以得知, Adobe Audition 降噪预测模型训练集的决定系数都大于 0.72, 且其中 4 组降噪预测模型的决定系数大于 0.8; 测试集的决定系数都大于 0.62; 均方根误差范围在 7~12.1 MPa 之间, 平均绝对误差范围在 5~9 MPa 之间。

表 4 降噪预测模型结果

Table 4 Noise reduction prediction model results

降噪方法		小波降噪						Adobe Audition 降噪					
隐含层	种群数	训练集			测试集			训练集			测试集		
		R^2 1	$RMSE$ 1	MAE 1	R^2 2	$RMSE$ 2	MAE 2	R^2 1	$RMSE$ 1	MAE 1	R^2 2	$RMSE$ 2	MAE 2
5	70	0.722	9.762	7.504	0.671	11.235	7.739	0.754	9.126	6.704	0.707	10.144	7.667
8	30	0.781	9.226	7.112	0.613	10.995	7.464	0.820	7.839	5.796	0.720	10.021	7.464
10	70	0.739	10.106	7.004	0.659	11.206	8.331	0.747	9.253	6.971	0.739	9.673	7.301
12	60	0.764	9.115	6.709	0.718	10.487	7.649	0.773	8.705	6.161	0.673	11.106	7.534
15	100	0.745	9.577	7.441	0.695	10.533	8.027	0.724	9.686	7.273	0.724	9.920	7.193
18	60	0.817	7.635	5.896	0.687	10.725	7.229	0.838	7.063	5.347	0.734	9.342	7.121
20	60	0.805	8.201	5.906	0.728	10.114	7.953	0.812	8.032	5.745	0.642	12.011	8.797
22	20	0.752	9.416	7.212	0.649	11.805	8.557	0.804	8.189	5.904	0.624	11.195	8.324
25	20	0.772	9.207	6.973	0.662	11.217	8.769	0.789	8.687	6.291	0.633	10.200	7.629

在 Adobe Audition 降噪预测模型中, 结合最优结果的拟合效果图如图 24, 隐含层为 8, 18, 20, 22 的 4 组训练集决定系数大于 0.8, 分别为 0.820, 0.838, 0.812, 0.804, 隐含层为 18、种群数为 60 的一组训练集决定系数最大; 与之对应, 隐含层为 8, 18, 20, 22 的 4 组测试集决定系数分别为 0.720, 0.734, 0.642, 0.624, 其中隐含层为 18、种群数为 60 的一组测试集决定系数最大; 训练集均方根误差最小值为 7.063 MPa, 平均绝对误差最小为 5.347 MPa; 测试集均方根误差最小值为 9.673 MPa, 平均绝对误差最小为 7.193 MPa。综上, 经对比分析各个参数的大小, 隐含层为 18、种群数为 60 的一组为降噪预测模型中最优的一组。

4.3.3 降噪前后预测模型效果分析

通过对比分析 4.3.1 节与 4.3.2 节降噪前后和不同降噪方法预测结果可知:




图 21 Adobe Audition 降噪预测模型 R^2 结果

Fig.21 Adobe Audition Noise reduction prediction model R^2 results

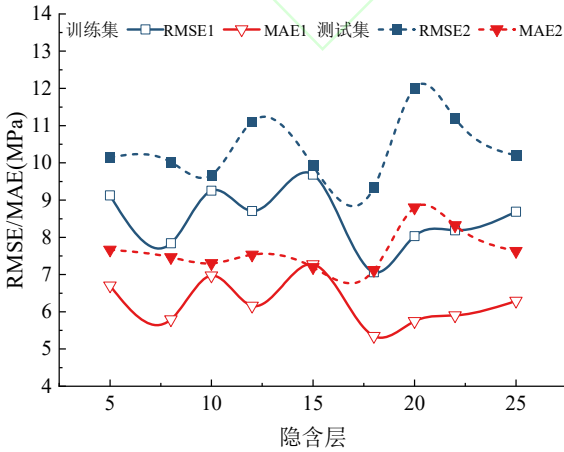


图 22 Adobe Audition 降噪预测模型 RMSE 和 MAE 结果

Fig.22 Adobe Audition Noise reduction prediction model RMSE and MAE results

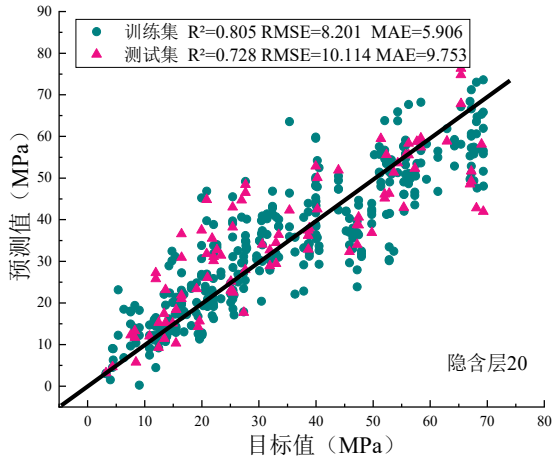


图 23 小波降噪预测模型拟合效果图

Fig.23 Wavelet Noise Reduction Prediction Model Fitting Results




图 24 Adobe Audition 降噪预测模型拟合效果图

Fig.24 Adobe audition noise reduction prediction model fitting results

- (1) 在原始预测模型中, 当隐含层为 5、种群数为 40 时预测结果最优, 训练集和测试集决定系数分别为 0.775、0.737, 均方根误差分别为 9.017, 10.452 MPa, 平均绝对误差分别为 6.968, 7.928 MPa。
- (2) 在降噪预测模型中, 采用小波降噪方法, 当隐含层为 20、种群数为 60 时预测结果最优, 训练集和测试集决定系数分别为 0.805, 0.728, 均方根误差分别为 8.201, 10.114 MPa, 平均绝对误差分别为 5.906, 9.753 MPa。
- (3) 在降噪预测模型中, 采用 Adobe Audition 降噪方法, 当隐含层为 18、种群数为 60 时预测结果最优, 训练集和测试集决定系数分别为 0.838, 0.734, 均方根误差分别为 7.063, 10.342 MPa, 平均绝对误差分别为 5.347, 7.320 MPa。
- (4) 对比两种降噪方法的预测模型, Adobe

Audition 降噪预测模型效果优于小波降噪预测模型, 常用的滤波降噪方法无法充分放大提取振动信号特征, 而结合 **Adobe Audition** 软件整体分离岩石振动信号与钻机空转振动信号的效果更加显著, 且降噪过程更加简略。

(5) 降噪预测模型的预测结果整体优于原始预测模型, 对比原始预测模型与最优的降噪预测模型结果(如图 25)采用 **Adobe Audition** 降噪方法的模型




图 25 降噪前后最优结果对比图

Fig.25 Comparison of optimal results before and after noise reduction

的训练集在预测精度上提升了 6.3%, 均方根误差减小 1.954 MPa, 平均绝对误差减小 1.621 MPa; 降噪后测试集的预测精度提升幅度较小, 均方根误差减小 1.11 MPa, 平均绝对误差减小 0.807 MPa。

4.3.4 不同岩性预测效果分析

降噪预测模型可以有效提升预测准确度, 不同岩性之间是否存在差异性还需进一步进行分析。故以最优降噪模型结果为例, 分别将煤、砂岩、石灰岩和花岗岩 4 种岩性的预测效果拟合图(如图 26)进行对比分析, 得到了以下结果:

四种岩性中, 石灰岩拟合度最高为 0.891, 高于总体拟合度 0.838; 砂岩和煤拟合度略低于总体水平, 分别为 0.785、0.746; 而花岗岩拟合度最差为 0.157, 与其他三种岩性拟合度都相差甚远。

构建的预测模型中, 砂岩试件数量最多, 石灰岩试件数量最少, 煤试件与花岗岩试件数量相当, 花岗岩出现拟合度极低的现象应与试件数量无关。从试件强度分布角度分析(试件强度分布详见 2.1 节), 煤与砂岩试件强度分布是在其强度范围内大致为均匀分布, 石灰岩强度分布集中于两端, 花岗岩分布于 39~70 MPa, 但 39~60 MPa 之间的试件数量较少, 大多集中于 60~70 MPa, 分布不均匀。从

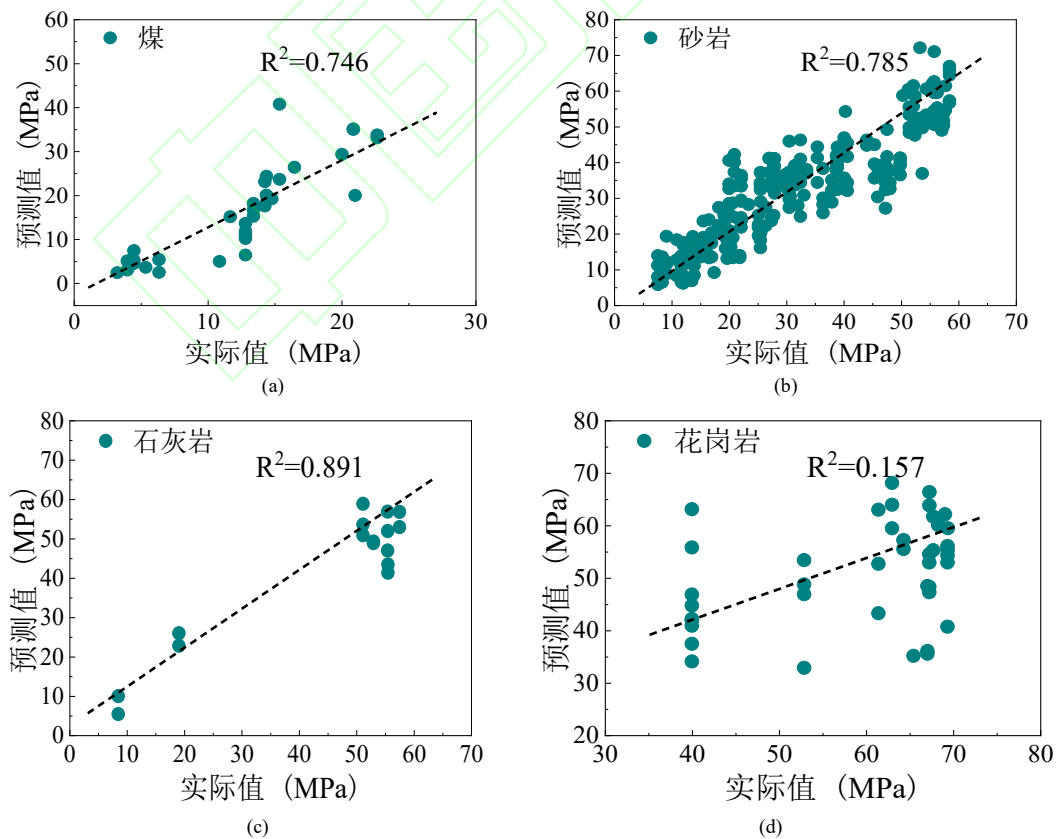


图 26 不同岩性预测效果拟合图

Fig.26 Fitting diagram of different lithology prediction effect

四种岩性试件钻进信号采集过程分析, 钻进时, 花岗岩质地坚硬, 钻进相对困难, 其钻进振动信号振动时域幅值是四种岩性中最大的, 与其余三种岩性振动信号存在一定差异。

综上, 此预测模型针对煤、砂岩、石灰岩三种岩性的预测效果较好, 对花岗岩的预测效果差。使得预测模型中花岗岩拟合度异常的原因或与其强度分布和钻进振动信号有关, 具体原因还需进一步探索。

5 结论与展望

5.1 结论

本文以岩石室内钻取实验为基础, 提出了钻进振动信号对岩石单轴抗压强度预测的研究方法。以降噪前后钻进振动信号为输入, 岩石单轴抗压强度为输出, 建立了原始信号 GA-BP 神经网络预测模型和降噪信号 GA-BP 神经网络预测模型。经对比分析, 得到如下结论:

(1) 岩石钻进振动信号与岩石单轴抗压强度之间具有较强响应关系, 所构建的预测模型准确度均在 77% 以上, 应用钻进振动信号时域、频域特征值可有效感知、预测岩石单轴抗压强度。

(2) 钻进振动信号经降噪处理使得岩石钻取过程中的振动特征更为明显。对比常用的滤波降噪方法, 采用 Adobe Audition 软件对钻机空转振动信号整体去除的新降噪方法更加简便, 降噪效果也更显著。原始振动信号特征值与岩石单轴抗压强度相关性较强的有 6 个参数, 其决定系数 R^2 在 0.4~0.5 之间; 降噪后的振动信号特征值与岩石单轴抗压强度相关性较强的有 7 个参数, 其决定系数 R^2 在 0.7~0.8 之间; 可见, 对振动信号进行降噪处理确有优良效果。

(3) 同一预测模型中不同岩性的预测效果存在一定差异, 根据预测结果, 最优降噪预测模型中对煤、砂岩、石灰岩三种岩石的预测效果较好, 而对花岗岩的预测效果较差。

(4) 本文构建的 GA-BP 神经网络预测模型可较为准确的预测岩石单轴抗压强度。GA-BP 神经网络预测模型降噪前后决定系数 R^2 分别可达到 0.775、0.838, 均方根误差最优分别可达到 9.017, 7.063 MPa, 平均绝对误差最优分别可达到 6.968, 5.347 MPa。对比可见, 降噪后模型在预测精度上提升了 6.3%, 均方根误差减小 1.954 MPa, 平均绝对误差减

小 1.621 MPa。降噪信号 GA-BP 神经网络预测模型可为岩体地质力学参数智能感知预测提供参考。

5.2 展望

(1) 本文所构建的神经网络预测模型仅以原始振动信号全部特征值共 26 个为输入进行网络学习训练, 并未考虑各特征值对预测结果的影响程度, 可采取适当方法对输入参数进行降维处理, 简化网络结构, 优化网络学习运行效率。

(2) 机器学习方法众多, 本文仅采用人工神经网络一种方法进行预测并不全面, 可采用多种模型方法分析岩石钻进振动信号与岩体地质力学参数之间的关系。

(3) 本文采用了直接降噪法将钻机空转时的振动信号从源信号中剥离, 使得模型预测值可达到 0.838, 但预测精度仍有提升空间, 力求更为行之有效的降噪方法使得预测精度更进一步。

(4) 以室内实验为主的研究仅提供了研究方法和思路, 现场应用时, 应以钻机替代室内取芯机, 结合现场围岩应力构建神经网络预测模型。

参考文献(References):

- [1] 田昊, 李术才, 薛翊国, 等, 基于钻进能量理论的隧道凝灰岩地层界面识别及围岩分级方法[J]. 岩土力学, 2012, 33(8): 2457 - 2464.(TIAN Hao, LI Shu-cai, XUE Yi-guo, et al., Identification of interface of tuff stratum and classification of surrounding rock of tunnel using drilling energy theory[J]. Rock and Soil Mechanics, 2012, 33(8): 2457 - 2464.(in Chinese))
- [2] 谭卓英, 李文, 岳鹏君, 等, 基于钻进参数的岩土地层结构识别技术与方法[J]. 岩土工程学报, 2015, 37(7): 1328 - 1333.(TAN Zhuoying, LI Wen, YUE Pengjun, et al., Techniques and approaches for identification of geo-formation structure based on diamond drilling parameters[J]. Chinese Journal of Geotechnical Engineering, 2015, 37(7): 1328 - 1333.(in Chinese))
- [3] LIU J K, LUAN H J, ZHANG Y C, et al., Prediction of unconfined compressive strength ahead of tunnel face using measurement-while-drilling data based on hybrid genetic algorithm[J]. Geomechanics and Engineering, 2020, 22(1): 81 - 95.
- [4] DAVOODIS, MEHRAD M, WOOD D A, et al., Predicting uniaxial compressive strength from drilling variables aided by hybrid machine learning[J]. International Journal of Rock Mechanics and Mining Sciences, 2023, 170: 105546.
- [5] 吕祥锋, 曹立厅, 孟令峰, 等, 旋压触探随钻摩阻表征围岩应力分

- 布特征研究[J]. 岩石力学与工程学报, 2023, 42(10): 2 385 - 2 399. (LYU Xiangfeng, CAO Liting, MENG Lingfeng, et al., Surrounding rock stress distribution characterization via drilling friction resistance while rotary sounding[J]. Chinese Journal of Rock Mechanics and Engineering, 2023, 42(10): 2 385 - 2 399.(in Chinese))
- [6] MOMENI E, ARMAGHANI D J, HAJIHASSANI M, et al., Prediction of uniaxial compressive strength of rock samples using hybrid particle swarm optimization-based artificial neural networks[J]. Measurement, 2015, 60: 50 - 63.
- [7] H. Sun, W.S. Du, C. Liu, Uniaxial Compressive Strength Determination of Rocks Using X-ray Computed Tomography and Convolutional Neural Networks[J]. Rock Mechanics and Rock Engineering, 2021, 54(8): 4 225 - 4 237.
- [8] 孙 欢, 刘晓丽, 王恩志, 等, 基于 X 射线断层扫描预测岩石单轴抗压强度[J]. 岩石力学与工程学报, 2019, 38(52): 3 575 - 3 582. (SUN Huan, LIU Xiaoli, WANG Enzhi, et al. Prediction on uniaxial compression strength of rocks with X-ray computed tomography[J]. Chinese Journal of Rock Mechanics and Engineering, 2019, 38(52): 3 575 - 3 582.(in Chinese))
- [9] B. SAEDI, S.D. Mohammadi, Prediction of uniaxial compressive strength and elastic modulus of migmatites by microstructural characteristics using artificial neural networks[J]. Rock Mechanics and Rock Engineering, 2021, 54(11): 5 617 - 5 637.
- [10] Y.M. Li, G.F. Zhao, A numerical integrated approach for the estimation of the uniaxial compression strength of rock from point load tests [J]. International Journal of Rock Mechanics and Mining Sciences, 2021, 148: 104939.
- [11] T.Y. Zhao, C. Song, S.F. Lu, et al., Prediction of Uniaxial Compressive Strength Using Fully Bayesian Gaussian Process Regression (fB-GPR) with Model Class Selection[J]. Rock Mechanics and Rock Engineering, 2022, 55(10): 6 301 - 6 319.
- [12] W.Z. Meng, W. Wu, Machine Learning-Aided Prediction of the Mechanical Properties of Frozen Fractured Rocks[J]. Rock Mechanics and Rock Engineering, 2023, 56(1): 261 - 273.
- [13] 王玉杰, 余 磊, 赵宇飞, 等, 基于数字钻进技术的岩石强度参数测定试验研究[J]. 岩土工程学报, 2020, 42(9): 1 659 - 1 668. (WANG Yujie, SHE Lei, ZHAO Yufei, et al. Experimental study on measurement of rock strength parameters based on digital drilling technology[J]. Chinese Journal of Geotechnical Engineering, 2020, 42(9): 1 659 - 1 668.(in Chinese))
- [14] S. Aboutaleb, M. Behnia, R. Bagherpour, et al., Using non-destructive tests for estimating uniaxial compressive strength and static Young's modulus of carbonate rocks via some modeling techniques[J]. Bulletin of Engineering Geology and the Environment, 2018, 77(4): 1 717 - 1 728.
- [15] 岳中琦, 李焯芬, 罗锦添, 等, 香港大学钻孔过程数字监测仪在土钉加固斜坡工程中的应用[J]. 岩石力学与工程学报, 2002, 21(11): 1 685 - 1 690.(YUE Z Q, LEE C F, LAW K T, et al., Use of HKU drilling process monitor in slope stabilization[J]. Chinese Journal of Rock Mechanics and Engineering, 2002, 21(11): 1 685 - 1 690.(in Chinese))
- [16] 岳中琦. 钻孔过程监测(DPM)对工程岩体质量评价方法的完善与提升[J]. 岩石力学与工程学报, 2014, 33(10): 1 977 - 1 996.(YUE Zhongqi, Drilling process monitoring for refining and upgrading rock mass quality classification methods[J]. Chinese Journal of Rock Mechanics and Engineering, 2014, 33(10): 1 977 - 1 996.(in Chinese))
- [17] W. Qi, G. Hongke, J. Bei, et al., Relationship model for the drilling parameters from a digital drilling rig versus the rock mechanical parameters and its application[J]. Rock Mechanics and Rock Engineering, 2018, 11: 357.
- [18] 王 琦, 高红科, 蒋振华, 等, 地下工程围岩数字钻探测试系统研发与应用[J]. 岩石力学与工程学报, 2020, 39(2): 301 - 310.(WANG Qi, GAO Hongke, JIANG Zhenhua, et al., Development and application of a surrounding rock digital drilling test system of underground engineering[J]. Chinese Journal of Rock Mechanics and Engineering, 2020, 39(2): 301 - 310.(in Chinese))
- [19] 郭书英, 马念杰. 岩层破裂状态与钻削机构振动响应特性研究[J]. 采矿与安全工程学报, 2016, 33(5): 911 - 916.(G. Shuying, M.A. Nianjie, Strata fracturing state and vibration response characteristics of drill[J]. Journal of Mining and Safety Engineering, 2016, 33(5): 911 - 916.(in Chinese))
- [20] 刘 刚, 张家林, 刘 闯, 等, 钻头钻进不同介质时的振动信号特征识别研究[J]. 振动与冲击, 2017, 36(8): 71 - 78, 104.(L. Gang, Z. Jialin, L. Chuang, et al., An identification method of vibration signal features when bit drills different mediums[J]. Journal of Vibration and Shock, 2017, 36(8): 71 - 78, 104.(in Chinese))
- [21] S. Liu, M. Fu, H. Jia, et al., Numerical simulation and analysis of drill rods vibration during roof bolt hole drilling in underground mines[J]. International Journal of Mining Science and Technology, 2018, 28(6): 877 - 884.
- [22] Chen, Lx., Guo, Wy., Jiang, Yj.et al. Experimental study on influence of lithology on directional propagation law of type-I cracks. J. Cent. South Univ. 2023, 30: 3 322 - 3 334
- [23] CHEN L xin, GUO W yao, ZHANG D xiao et al. Experimental study

- on the influence of prefabricated fissure size on the directional propagation law of rock type-I crack[J]. International Journal of Rock Mechanics and Mining Sciences, 2022, 160: 105274.
- [24] E. Lazarova, M. Krulakova, V. Krupa, et al., Regime and rock identification in disintegration by drilling based on vibration signal differentiation[J]. International Journal of Rock Mechanics and Mining Sciences, 2022, 149: 104984.
- [25] 陈晓君, 陈根龙, 宋刚, 等, 基于岩石性质的钻进振动响应分析[J]. 探矿工程: 岩土钻掘工程, 2019, 46(10): 20 - 26.(C. Xiaojun, C. Genlong, S. Gang, et al., Analysis of drilling vibration response based on rock properties[J]. Exploration Engineering(Rock & Soil Drilling and Tunneling), 2019, 46(10): 20 - 26.(in Chinese))
- [26] M. Klaić, Z. Murat, T. Staroveski, et al., Tool wear monitoring in rock drilling applications using vibration signals[J]. Wear, 2018, 408: 222 - 227.
- [27] Y. Yang, Q.L. Zeng, G.J. Yin, et al., Vibration Test of Single Coal Gangue Particle Directly Impacting the Metal Plate and the Study of Coal Gangue Recognition Based on Vibration Signal and Stacking Integration[J]. Ieee Access, 2019, 7: 106 783 - 106 804.
- [28] 李彦忠, 胡坤, 汪浅予, 等, 基于随钻振动信号对钻进介质的识别研究[J]. 煤矿机电, 2022, 43(2): 1 - 5, 16.(Y. LI, H. Kun., W. Qianyu., Research on Identification of Drilling Medium Based on Vibration Signal While Drilling[J]. Colliery Mechanical & Electrical Technology, 2022, 43(2): 1 - 5, 16.(in Chinese))
- [29] M. Liu, S. Liao, Y. Yang, et al., Tunnel boring machine vibration-based deep learning for the ground identification of working faces[J]. Journal of Rock Mechanics and Geotechnical Engineering, 2021, 13(6): 1 340 - 1 357.
- [30] A.I. Lawal, S. Kwon, O.S. Hammed, et al., Blast-induced ground vibration prediction in granite quarries: An application of gene expression programming, ANFIS, and sine cosine algorithm optimized ANN[J]. International Journal of Mining Science and Technology, 2021, 31(2): 265 - 277.
- [31] C. Li, R. Huang, Y. Yi, et al., Investigation of Filtering Algorithm for Noise Reduction in Displacement Sensing Signal[J]. Ieee Sensors Journal, 2021, 21(6): 7 808 - 7 812.
- [32] M.Q. Miao, Y.H. Sun, J.B. Yu, Deep sparse representation network for feature learning of vibration signals and its application in gearbox fault diagnosis[J]. Knowledge-Based Systems, 2022, 240: 108116.
- [33] Z.H. Yu, L. Zhu, B. Dai, et al., Noise Reduction Based on Adaptive Prediction Fitting Algorithm for a Heterodyne Phi-OTDR System[J]. Ieee Photonics Technology Letters, 2022, 34(23): 1 311 - 1 314.
- [34] M. Qin, K. Wang, K. Pan, et al., Analysis of signal characteristics from rock drilling based on vibration and acoustic sensor approaches[J]. Applied Acoustics, 2018, 140: 275 - 282.
- [35] H.J. Ren, A.J. Yin, Q. Zhang, Vibration signal denoising using partial differential equations of arbitrary order[J]. Measurement, 2019, 148: 106917.
- [36] Z. Ye, J. B. Yu, Deep morphological convolutional network for feature learning of vibration signals and its applications to gearbox fault diagnosis[J]. Mechanical Systems and Signal Processing, 2021, 161: 107984.